

Estatísticas de Testes de Hipóteses: Teoria e Aplicações

Gabriela Aimee Scarpini Silva

Orientador: Victor Fossaluza

1. Introdução

A inferência estatística concentra-se em dois tipos de problemas: estimação e teste de hipóteses, sendo o último o foco deste trabalho. Uma *hipótese estatística* é uma afirmação sobre um parâmetro θ . Um teste de hipóteses consiste em um problema de decisão, em que deve-se escolher uma entre duas (ou mais) hipóteses. No caso mais comum da prática estatística, em que tem-se duas hipóteses, o espaço paramétrico é dividido em subconjuntos complementares, Θ_0 e $\Theta_1 = \Theta_0^c$. Às afirmações $H_0 : \theta \in \Theta_0$ e $H_1 : \theta \in \Theta_0^c$ dá-se o nome de *hipótese nula* e *hipótese alternativa*, respectivamente.

Um **teste de hipóteses** $\varphi : \mathcal{X} \rightarrow \{0, 1\}$ é uma regra de decisão que especifica para quais pontos $x \in \mathcal{X}$ a hipótese $H_0 : \theta \in \Theta_0$ deve ser rejeitada ($\varphi(x) = 1$) ou aceita ($\varphi(x) = 0$). O subconjunto do espaço amostral $\mathcal{X}$ que contém os pontos que levam à rejeição de H_0 ($\varphi^{-1}(\{1\})$) é chamada *região crítica* (RC) ou *região de rejeição* do teste φ .

A região crítica pode ser expressa por meio de uma **estatística de teste**, $W(X)$, que, em geral, é função de uma estatística suficiente. Essa estatística é utilizada para ordenar o espaço amostral de modo que grandes valores de W indicam pontos mais favoráveis à $H_0 : \theta \in \Theta_0$.

Nesta pesquisa, abordaremos quatro medidas de estatísticas de teste e, através de exemplos, compararemos as medidas para avaliar a consistência das conclusões.

2. Estatísticas de Teste

Seja $\mathbf{X} = (X_1, X_2, \dots, X_n)$ variáveis aleatórias condicionalmente independentes e identicamente distribuídas (v.a. c.i.i.d.), com função de densidade de probabilidade ou função de probabilidade (f.d.p) $f(\mathbf{x}|\theta)$, em que $\theta \in \Theta$.

Consideramos o teste de hipótese

$$H_0 : \theta \in \Theta_0 \text{ contra } H_1 : \theta \neq \theta_0^c$$

com $\Theta_0 \subseteq \Theta$.

Uma estatística de teste $W : \mathfrak{X} \rightarrow \mathbb{R}$ é uma função do espaço amostral que sumariza as evidências contidas na amostra em um único valor numérico, permitindo analisar a compatibilidade dos dados com H_0 .

2.1 Razão de Verossimilhança Generalizada (RVG)

A função de verossimilhança desempenha papel fundamental nas diferentes escolas de inferência estatística e é definida por $V_x : \Theta \rightarrow \mathbb{R}$, $V_x(\theta) = f(x|\theta)$.

Sob o enfoque bayesiano, a incerteza sobre o parâmetro θ é descrita em termos de uma distribuição de probabilidade $f(\theta)$, chamada distribuição a priori. Essa incerteza é atualizada após a distribuição de $\mathbf{X} = \mathbf{x}$ via Teorema de Bayes

$$f(\theta|x) = \frac{f(x|\theta)f(\theta)}{f(x)} \propto V_x(\theta)f(\theta)$$

A RVG é uma ferramenta da estatística frequentista usada para medir quanto H_0 é suportado pelos dados observados, em relação ao panorama de máximo verossimilhança global ($\sup_{\Theta} V_x(\theta)$).

Seja $V_x(\theta)$ a função de verossimilhança da nossa amostra $\mathbf{X}$, definida sobre o espaço paramétrico Θ . A RVG é definida por:

$$\lambda(x) = \frac{\sup_{\Theta_0} V_x(\theta)}{\sup_{\Theta} V_x(\theta)}$$

O denominador representa o valor máximo da função de verossimilhança, ou seja, o valor de $V_x(\theta)$ calculada no Estimador de Máximo Verossimilhança (EMV) $\hat{\theta}_{MV}$ e o numerador é o máximo sob H_0 . Por definição, a RVG $\in (0, 1]$. Sendo igual a 1 somente quando $\hat{\theta}_{MV} \in \Theta_0$.

2.2. p-value

Dada uma estatística de teste $W(\mathbf{X})$, o *p-value* é definido como a maior probabilidade, sob H_0 , de se observar um valor da estatística de teste mais desfavoráveis à hipótese nula que aquele de fato observado ($W(x)$):

$$p(x) = \sup_{\Theta_0} P(W(X) \leq W(x)|\theta).$$

p-values pequenos mostram que o resultado observado seria improvável caso H_0 fosse verdadeira. Em contrapartida, *p-values* altos sugerem que os dados são compatíveis com H_0 .

2.3 Probabilidade a posteriori de H_0

A probabilidade a posteriori da Hipótese H_0 é obtida por

$$\pi(x) = P(\theta \in \Theta_0|x) = \int_{\Theta_0} f(\theta|x)d\theta$$

A estatística acima é a atualização da crença inicial sobre a hipótese de H_0 , baseada na evidência fornecida pelos dados. Diferente do *p-value*, essa quantidade possui uma interpretação de probabilidade mais clara, uma vez que, evidencia a probabilidade de a hipótese ser verdadeira, condicionada aos dados observados.

Valores altos de $\pi(x)$ mostram forte evidência empírica a favor de H_0 , enquanto valores baixos sugerem que H_0 é pouco plausível.

Para o caso de testes para hipóteses precisas, a probabilidade posterior será zero. Em termos matemáticos, $P(\theta \in \Theta_0|x) = 0$, se $\dim(\Theta_0) < \dim(\Theta)$.

2.4 e-value (Full Bayesian Significance Test - FBST)

Ainda sob a abordagem bayesiana, o *e-value* é uma medida de evidência desenvolvido especificamente para testar hipóteses precisas.

A região T_x representa os pontos do espaço paramétrico desfavoráveis à H_0 , e é definido como

$$T_x = \left\{ \theta \in \Theta : f(\theta|x) > \sup_{\Theta_0} f(\theta|x) \right\}$$

A partir disso, o *e-value* é definido por

$$Ev(x) = 1 - P(\theta \in T_x | x).$$

O FBST (Procedimento de Pereira-Stern) consiste em rejeitar H_0 para valores “pequenos” de $Ev(x)$.

2.2. Exemplos de modelos

Bernoulli-Beta:

Seja $X_1, \dots, X_n$ v.a. c.i.i.d tais que $X_i | \theta \sim \text{Bernoulli}(\theta)$.

A estatística suficiente para θ é a soma dos sucessos, denotada por $T(\mathbf{x}) = \sum_{i=1}^n X_i$, que segue uma distribuição Binomial, ou seja,

$$T(\mathbf{x}) = \sum_{i=1}^n X_i | \theta \sim \text{Bin}(n, \theta)$$

Suponha que a priori desse modelo seja uma priori conjugada $\theta \sim \text{Beta}(a, b)$. Por simplicidade, considere que exista razão para acreditar em nenhum valor, fixaremos os parâmetros como $a = 1$ e $b = 1$, ou seja, uma distribuição Uniforme no intervalo $(0, 1)$.

Considere que:

$$H_0 : \theta \leq 0.5 \text{ contra } H_1 : \theta > 0.5$$

Desse modo, o espaço paramétrico é $\Theta = [0, 1]$ e o subespaço de H_0 é $\Theta_0 = [0, 0.5]$.

É válido analisar o comportamento das estatísticas de teste para cada valor possível da estatística suficiente: $x = \sum_{i=1}^n x_i \in \{0, 1, \dots, n\}$.

Nesse exemplo a **RVG** é dada por:

$$\lambda(x) = \frac{V_x(0.5|x)}{V_x(x/n|x)} = \frac{0.5^x(1-0.5)^{n-x}}{(x/n)^x(1-x/n)^{n-x}}, \text{ se } x > n/2.$$


Se a estimativa pertence à $[0, 0.5]$, que acontece em $x \in \{0, \dots, n/2\}$, ou seja, se $\hat{\theta}_{MV} \leq 0.5$, o numerador e o denominador são iguais, logo $\lambda(x) = 1$.

Já para o cálculo do **p-value** buscamos o supremo da probabilidade na região de rejeição sob o espaço da hipótese nula $\Theta_0 = [0, 0.5]$. Assim, calculamos a probabilidade de uma variável $X \sim \text{Binomial}(n, 0.5)$ ser maior ou igual ao valor observado x . Como a probabilidade de obter sucessos aumenta com θ , o valor máximo ocorre em $\theta = 0.5$.

$$\text{p-value} = P(X \geq x \mid \theta = 0.5) = \begin{cases} \sum_{k=x}^n \binom{n}{k} (0.5)^k (1 - 0.5)^{n-k} & \text{se } x > n/2 \\ 1 & \text{se } x \leq n/2 \end{cases}$$


Note que o máximo a posteriori (ou a moda da Beta) é $\frac{x}{n}$. No caso que $x \leq n/2$, $T_x = \emptyset (= \{\theta : f(\theta|x) \geq f(\frac{x}{n}|x)\})$.

Gráfico 1: Sup em H0



Por outro lado, se $x > n/2$, $\sup_{\Theta_0} f(\theta|x) = f(0.5|x)$, de modo que $T_x \neq \emptyset$ e $e\text{-value} < 1$. A obtenção da região T_x e o cálculo do $e\text{-value}$ serão realizadas computacionalmente pois o cálculo analítico não possui forma fechada.

Gráfico 2: Sup na fronteira




A distribuição posterior é Beta: $\theta|x \sim \text{Beta}(a+x, b+n-x)$. Queremos calcular $P(\theta \in \Theta_0|x)$, ou seja, área sob a curva da f.d.p. posterior que pertence à hipótese nula ($\theta \leq 0.5$).

$$\pi(x) = P(\theta \leq 0.5|x) = \int_0^{0.5} f(\theta|1+x, 1+n-x)d\theta$$

Suponha que foi observado $n = 10$, $x = \sum_{i=1}^{10} x_i$ e, a priori $a = b = 1$. Então, a distribuição a posteriori é $\text{Beta}(1+x, 11-x)$.

Os gráficos a seguir mostram as medidas de evidência a favor da hipótese nula ($H_0 : \theta \leq 0.5$) diminuem à medida que o número de sucessos (x) aumenta.



Exponencial-Gama:

Seja $X_1, \dots, X_n$ v.a. c.i.i.d. tal que $X_i|\theta \sim \text{Exp}(\theta)$. A função densidade é dada por $f(x|\theta) = \theta e^{-\theta x}$.

Nesse caso, a estatística suficiente é a soma dos tempos observados: $T(\mathbf{x}) = \sum_{i=1}^n x_i$. Temos que soma de n Exponenciais (θ) segue uma distribuição Gama:

$$T(\mathbf{x}) \sim \text{Gama}(n, \lambda)$$

Suponha que

$$H_0 : \theta = 1.5 \quad \text{contra} \quad H_1 : \theta \neq 1.5$$

O valor esperado da nossa estatística suficiente será $E[T] = n/\theta = n/1.5$.

A **RVG** é dada por:

$$\lambda(x) = \frac{V_x(1.5|x)}{V_x(x/n|x)} = \frac{1.5^n e^{-1.5T}}{\left(\frac{n}{T}\right)^n e^{-\frac{n}{T}T}} = \frac{1.5^n e^{-1.5T}}{\left(\frac{n}{T}\right)^n e^{-n}}$$


Observa-se que para a estatística suficiente próxima de $E[T]$ o p -value será muito alto, já que a soma observada é a mesma da hipótese nula. Já para valores baixos ou altos o p -value cairá.

A distribuição posterior é Gama: $\theta|\mathbf{x} \sim \text{Gama}(\alpha_{post} = 12, \beta_{post} = 1 + x)$. Como o teste é preciso a posteriori será zero: $P(\theta \in \Theta_0|x) = 0$.

Admita que a priori para o θ seja Gama, com parâmetros $\alpha = 2$ e $\beta = 1$. Suponha também que foi observado uma amostra de tamanho $n = 10$. Nesse caso, $E[T] = n/\theta = 10/1.5 \approx 6.667$

Será analisado o comportamento das estatísticas de teste para uma sequência de valores $\mathbf{x}$ (soma), em torno da média esperada (variando de 2 a 18), $x = \sum_{i=1}^{10} x_i \in \{2, \dots, 18\}$.

Nos gráficos a seguir, é possível observar que o RVG, o p -value e o e -value são parecidos, neles o pico ocorre exatamente em $x \approx 6.667$, onde os dados são mais compatíveis com a hipótese nula.



Uniforme-Pareto:

Seja $X_1, \dots, X_n$ v.a. c.i.i.d. tal que $X_i|\theta \sim \text{Uniforme}(0, \theta)$. A função de densidade é $f(x|\theta) = 1/\theta$ para $0 \leq x \leq \theta$.

Para esse caso, a estatística suficiente para θ é o máximo valor observado:

$$T(\mathbf{x}) = \max(X_1, \dots, X_n)$$

Sendo assim, o parâmetro θ deve ser necessariamente maior ou igual ao maior valor observado ($\theta \geq T(\mathbf{x})$).

Suponha que a priori para o limite da Uniforme tenha uma distribuição Pareto: $\theta \sim \text{Pareto}(\alpha, x_m)$. Sua função de densidade de probabilidade é:

$$f(\theta) = \frac{\alpha x_m^\alpha}{\theta^{\alpha+1}}$$

Suponha que

$$H_0 : \theta = 15 \quad \text{contra} \quad H_1 : \theta \neq 15$$

Diferente das distribuições anteriores, a verossimilhança da Uniforme decai para zero abruptamente. Se o máximo observado for maior que 15 ($x > 15$), a hipótese nula é impossível. Neste caso, RVG, p-value e e-value devem ser zero.

Para $x \leq 15$, a **RVG** é dada por

$$\lambda(x) = \frac{V_x(15)}{V_x(x)} = \frac{1/15^n}{1/x^n} = \left(\frac{x}{15}\right)^n$$

Com isso,

$$\lambda(x) = \begin{cases} \left(\frac{x}{15}\right)^n & \text{se } x \leq 15 \\ 0 & \text{se } x > 15 \end{cases}$$

Para o cálculo do *p-value*, se o $x_{max} \leq 15$ a probabilidade de que os n elementos da amostra sejam menores ou iguais a um valor x é:

$$P(X_{max} \leq x) = \left(\frac{x}{15}\right)^n$$


Para algum valor na amostra maior que 15, a probabilidade disso acontecer sob a hipótese nula ($\theta = 15$) é zero. Logo, o p-value é 0.

Já a distribuição posterior tem distribuição Pareto, com parâmetros: $\alpha_{post} = \alpha + n = 3 + n = 11$ e $x_{m,post} = \max(x_m, T(\mathbf{x})) = \max(10, \max(X_i))$. Mas como o teste é preciso a posteriori será zero: $P(\theta \in \Theta_0 | x) = 0$.

Admita que $n = 8$ e que a priori para o limite da Uniforme tenha uma distribuição Pareto, com parâmetros: $\theta \sim \text{Pareto}(\alpha = 3, x_m = 10)$

Será analisado o comportamento das estatísticas de teste para uma sequência de valores x (máximo), variando de 10 (mínimo da priori) a 16, $x \in \{10, \dots, 16\}$.

Os gráficos a seguir mostram que O RVG, o p-value e o e-value possuem uma forma parecida, a medida aumenta conforme o dado observado (x) se aproxima de 15, atingindo o máximo em $x = 15$. Assim que $x > 15$, ela cai para 0.



4. Conclusão e Próximos Passos

A análise comparativa realizada nesse projeto permitiu observar o comportamento de diferentes estatísticas de teste sob uma variedade de modelos probabilísticos. Os resultados mostram que a Razão de Verossimilhança Generalizada, o p -value e o e -value atingem seu máximo quando os dados observados coincidem com o valor esperado sob H_0 .

A continuidade do projeto focará na transição da análise teórica para a aplicação prática das metodologias em dados reais provenientes do Centro de Estatística Aplicada (IME-USP) para a comparação de decisões inferenciais com base em diferentes métricas de evidência.

Além disso, buscaremos analisar formalmente os valores de corte para as estatísticas de teste e desenvolver critérios de corte equivalentes para o e-value, buscando estabelecer zonas de rejeição e aceitação que mantenham a coerência com as propriedades do FBST.

Desse modo, espera-se consolidar a interpretação das estatísticas de teste, fornecendo ferramentas interpretativas que contribuam na tomada de decisão em problemas de teste de hipótese.

Bibliografia

- [1] Fossaluza, V., Izbicki, R., da Silva, G. M. and Esteves, L. G. Coherent hypothesis testing. *The American Statistician*, 71(3), pp.242-248, 2017.
- [2] Pereira, C. A. de B., Stern, J. M., & Wechsler, S. Can a significance test be genuinely Bayesian? *Bayesian Analysis*, 3(1), 79–100, 2008.
- [3] Pereira, C. A. B., Stern, J. M. Evidence and credibility: Full bayesian significance test for precise hypotheses. *Entropy*, I(4):99-110, 1999.
- [4] Stern, J. M. Bayesian evidence test for precise hypotheses. *Journal of Statistical Planning and Inference*, 117(2), 185–198, 2003.
- [5] Schervish, M. J. P-values: what they are and What they are not. *The American Statistician*, 50, 203–206, 1996.
- [6] Madruga, M. R. Teste de significância: uma proposta genuinamente bayesiana. Tese (Doutorado), Instituto de Matemática e Estatística, Universidade de São Paulo (USP), 2002