

Simulação

Seja $X_i|\theta \sim Ber(\theta)$. Nossa priori é $\theta \sim Beta(a = 1, b = 1)$. Desse modo $Y = \sum X_i$ é estatística suficiente.

Queremos testar,

$$H_0 : \theta = 1/2$$

$$H_1 = \theta \neq 1/2$$

Para isso, simularemos m pares de $(\mathbf{X}, \theta)$, ou seja, $(\mathbf{X}, \theta)_j$, com $j = 1, \dots, m$.

p-value

Sabemos que o *p-value* mede o quão extremo o valor observado de $Y = \sum X_i$ é sob H_0 . Perceba que, sob H_0 , $\theta = 1/2$, ou seja, $Y|\theta \sim Bin(n, 1/2)$.

Então, depois de observar y_j , $j = 1, \dots, m$, queremos calcular

$$p(y) = \begin{cases} 2 \cdot P(Y \geq y | \theta = 1/2), & y > n/2 \\ 2 \cdot P(Y \leq y | \theta = 1/2), & y < n/2 \\ 1, & y = n/2 \end{cases}$$

No R,

```
p_valor <- function(y, n) {
  if (y > n/2) {
    p <- 2 * (1 - pbinom(y - 1, size = n, prob = 1/2))
  } else if (y < n/2) {
    p <- 2 * pbinom(y, size = n, prob = 1/2)
  } else {
    p <- 1
  }
  p <- min(p, 1)
  return(p)}

```

α : erro tipo I

O erro do tipo I acontece quando rejeitamos a hipótese nula, quando H_0 é verdadeira. Ou seja, $\alpha = P(\text{rejeitar } H_0 | \theta = 1/2)$

No R,

```
c_alpha <- function(n_atual, m){
  # simular sob H0
  y <- rbinom(m, size = n_atual, prob = 1/2)
  pvals <- sapply(y, p_valor, n = n_atual)
  alpha <- mean(pvals <= 0.05)
  return(alpha)}

```


β : erro tipo II

O erro do tipo II acontece quando não rejeitamos a hipótese nula, quando H_0 é falsa. Para calcular o nosso erro do tipo II, precisamos simular o nosso $\theta \in \Theta_A$ e a partir disso calcular o nosso β médio:

```
c_beta <- function(n_atual, m, a = 1, b = 1){
  theta <- rbeta(m, a, b) # theta ~ Beta(a,b)
  y <- rbinom(m, size = n_atual, prob = theta) # Y | theta
  pvals <- sapply(y, p_valor, n = n_atual) # p-valores
  beta <- mean(pvals > 0.05)
  return(beta)}

```


Gráfico



O gráfico foi construído para analisar como o tamanho da amostra n influencia o comportamento do teste. Para isso, foram considerados diferentes valores de n (5, 10, 20, 40, ..., 1000). Para cada valor de n , foram realizadas $m = 10000$ simulações e, a partir delas, foram calculados: o erro do tipo I (α), erro tipo II (β) e o p -value médio do teste.

No eixo x está o tamanho da amostra, enquanto no eixo y estão os valores estimados dessas três quantidades. Esse gráfico é bom para ter uma noção da tendência geral, conforme n cresce, mas ele não mostra a variabilidade dos dados.

Para conseguir visualizar essa variabilidade faremos um boxplot com “pontos”, que nos permitira ver a distribuição.



Nesse gráfico, conseguimos enxergar a concentração de p-values e nos outliers. Como esperado o teste rejeita a hipótese nula com mais frequência conforme o n cresce.