

Simulação

Seja $X_i|\theta \sim Ber(\theta)$. Nossa priori é $\theta \sim Beta(a = 1, b = 1)$. Desse modo $Y = \sum X_i$ é estatística suficiente.

Queremos testar,

$$H_0 : \theta = 1/2$$

$$H_1 = \theta \neq 1/2$$

Para isso, simularemos m pares de $(\mathbf{X}, \theta)$, ou seja, $(\mathbf{X}, \theta)_j$, com $j = 1, \dots, m$.

p-value

Sabemos que o *p-value* mede o quão extremo o valor observado de $Y = \sum X_i$ é sob H_0 . Perceba que, sob H_0 , $\theta = 1/2$, ou seja, $Y|\theta \sim Bin(n, 1/2)$.

Então, depois de observar y_j , $j = 1, \dots, m$, queremos calcular

$$p(y) = \begin{cases} 2 \cdot P(Y \geq y | \theta = 1/2), & y > n/2 \\ 2 \cdot P(Y \leq y | \theta = 1/2), & y < n/2 \\ 1, & y = n/2 \end{cases}$$

No R,

```
p_valor <- function(y, n) {
  if (y > n/2) {
    p <- 2 * (1 - pbinom(y - 1, size = n, prob = 1/2))
  } else if (y < n/2) {
    p <- 2 * pbinom(y, size = n, prob = 1/2)
  } else {
    p <- 1
  }
  p <- min(p, 1)
  return(p)}

```

α : erro tipo I

O erro do tipo I acontece quando rejeitamos a hipótese nula, quando H_0 é verdadeira. Ou seja, $\alpha = P(\text{rejeitar } H_0 | \theta = 1/2)$

No R,

```
c_alpha <- function(n_atual, m){
  # simular sob H0
  y <- rbinom(m, size = n_atual, prob = 1/2)
  pvals <- sapply(y, p_valor, n = n_atual)
  alpha <- mean(pvals <= 0.05)
  return(alpha)}

```


β : erro tipo II

O erro do tipo II acontece quando não rejeitamos a hipótese nula, quando H_0 é falsa. Para calcular o nosso erro do tipo II, precisamos simular o nosso $\theta \in \Theta_A$ e a partir disso calcular o nosso β médio:

```
c_beta <- function(n_atual, m, a = 1, b = 1){
  theta <- rbeta(m, a, b) # theta ~ Beta(a,b)
  y <- rbinom(m, size = n_atual, prob = theta) # Y | theta
  pvals <- sapply(y, p_valor, n = n_atual) # p-valores
  beta <- mean(pvals > 0.05)
  return(beta)}

```


Gráfico



O gráfico foi construído para analisar como o tamanho da amostra n influencia o comportamento do teste. Para isso, foram considerados diferentes valores de n (5, 10, 20, 40, ..., 1000). Para cada valor de n , foram realizadas $m = 10000$ simulações e, a partir delas, foram calculados: o erro do tipo I (α), erro tipo II (β) e o p -value médio do teste.

No eixo x está o tamanho da amostra, enquanto no eixo y estão os valores estimados dessas três quantidades. Esse gráfico é bom para ter uma noção da tendência geral, conforme n cresce, mas ele não mostra a variabilidade dos dados.

Para conseguir visualizar essa variabilidade faremos um boxplot com “pontos”, que nos permitira ver a distribuição.




Nesse gráfico, conseguimos enxergar a concentração de p-values e nos outliers. Como esperado o teste rejeita a hipótese nula com mais frequência conforme o n cresce.

Probabilidade a Posteriori

Foi simulado o *p-value* para diferentes valores de n , mas para a Probabilidade a Posteriori isso seria mais difícil, uma vez que nossa hipótese é precisa ($H_0 = 1/2$) e a priori é contínua ($\theta \sim \text{Beta}(a = 1, b = 1)$), sendo assim, a probabilidade de $\theta|Y = y = \sum x_i$ assumir qualquer valor é 0.

Uma das formas de calcular uma Probabilidade a Posteriori é usando a Priori de Jeffreys, que atribui uma probabilidade positiva para θ_0 .



Desse modo, é possível calcular $P(\theta = 1/2|X = x)$:

A distribuição preditiva com relação a priori f_J é

$$\begin{aligned}
 f_J(x) &= p_0 f(x|\theta_0) \mathbb{I}(\theta = \theta_0) + (1 - p_0) \overbrace{\int_0^1 f(x|\theta) f_\beta(\theta) \mathbb{I}(\theta \neq \theta_0) d\theta}^{f(x)} \\
 &= p_0 \binom{n}{x} \theta_0^x (1 - \theta_0)^{n-x} \mathbb{I}(\theta = \theta_0) + (1 - p_0) \binom{n}{x} \frac{\beta(a+x, b+n-x)}{\beta(a, b)} \mathbb{I}(\theta \neq \theta_0)
 \end{aligned}$$

De modo que a distribuição a posteriori é dada de forma geral por:

$$p_x = \frac{1}{1 + \frac{1-p_0}{p_0} \frac{B(a+x, b+n-x)}{(1/2)^n B(a, b)}}$$

Assumindo a priori de Jeffreys com a distribuição $Beta(1, 1)$ para a hipótese alternativa, substituímos

Para o denominador

$$B(1, 1) = \frac{\Gamma(1)\Gamma(1)}{\Gamma(2)} = 1$$

Já o numerador:

$$B(1+x, 1+n-x) = \frac{\Gamma(1+x)\Gamma(1+n-x)}{\Gamma(n+2)} = \frac{x!(n-x)!}{(n+1)!}$$

Podemos expressar esse resultado utilizando o coeficiente binomial

$$\frac{x!(n-x)!}{(n+1)!} = \frac{x!(n-x)!}{n!(n+1)} = \frac{1}{(n+1)\binom{n}{x}}$$


Substituindo tudo isso na equação, obtemos a probabilidade a posteriori:

$$p_x = \frac{1}{1 + \frac{1-p_0}{p_0} \frac{\binom{n}{x}}{(1/2)^n}}$$

$$p_x = \frac{1}{1 + \frac{1-p_0}{p_0} \frac{2^n}{\binom{n}{x}}}$$

Como feito com o *p-value* é válido observar o comportamento da probabilidade a posteriori (sob H_0 e sob H_1) conforme n cresce.

Probabilidade a Posteriori de H_0 usando Jeffreys
Sob H_0 vs Sob H_1



No gráfico acima, sob H_0 a mediana da probabilidade a posteriori começa ao redor de 0,6 ou 0,7 para n pequeno, e vai aumentando até chegar próximo de 1, ou seja, quanto maior n maior é a probabilidade de $\theta = 1/2$. Já sob H_1 os boxplot vão diminuindo até chegar próximo de 0.